新能源充电桩智能运维多 Agent 平台 —— 技术架构总览

图 1 · 总体架构（六层）

页面与对话共用同一份工具层与权限，保证「页面/对话结论永远同源」

L1 应用

- **运维后台** — 大屏/工单台/报表
- **移动 H5** — 现场运维
- **对话助手浮窗** — SSE 流式：查状态/问告警/日报
- **钉钉消息端** — 分级实时触达

▲ 统一 API 网关（鉴权 / 限流 / 审计 / 权限透传）

L3 AI 编排（核心）

- **主 Agent（编排中枢）** — LangGraph · 规则优先路由 + LLM 语义介入：事件路由·编排·仲裁·checkpointer·权限透传
- **感知子 Agent** — 脏数据清洗·滑动窗口稳态判断
- **告警研判子 Agent** — 降噪·真伪区分·ReAct 根因·P0-P3
- **工单子 Agent** — 草稿·派单·SLA·闭环
- **RAG 子 Agent** — 问答·案例检索·方案生成

▲ 结构化 JSON（Notification / Task / Result），子 Agent 全经主 Agent 中转

L4 能力支撑

- **滑动窗口稳态判断** — 连续 N 周期超阈值
- **ReAct 根因推理** — 取测点→查拓扑→检索历史→归因
- **三路置信度加权** — 规则40%+RAG35%+拓扑25%
- **分级处置 L0-L2** — 告警P0-P3 × 自动度
- **安全护栏链** — dry_run·爆炸半径·熔断·审批

L5 数据与知识

- **时序库 TDengine** — 电压/电流/温度/绝缘测点
- **业务库 PostgreSQL** — 工单/告警/台账/checkpoint
- **向量库** — 知识/案例 embedding
- **Redis** — 会话/任务状态缓存
- **RAG 知识库** — 手册/规程/历史案例

L6 基础设施

- **MQTT / EMQX** — 桩端测点 3~5s 上报
- **边缘网关** — 采集/汇聚
- **LLM 推理** — Qwen3 + ReAct 工具调用
- **定时调度** — 7:50 唤醒→自动日报
- **钉钉推送** — 分级强推

> **核心设计取舍：**规则粗筛 + LLM 语义介入**不是**「全交给大模型」——稳态判断、路由、熔断这些确定性活全在规则层，只把「根因推理」留给大模型；子 Agent 只经主 Agent 中转，保证单一编排入口，事件流水线和对话助手走**同一份共享工具层**，杜绝页面与对话数据不一致。

图 2 · 端到端数据流转主链路（每步标数据形态/落库/保留）

桩端测点 → 告警研判 → 分级处置 → 工单闭环 → 案例反哺；「设备上报告警码不可信，趋势才可信」 · 多站场快充桩多类测点按 3~5s 周期上报，边缘网关就近汇聚、EMQX 统一接入

① **测点上报** — MQTT 3~5s 原始时序测点 → **TDengine**(热 N 月)
→
② **稳态判断** — 滑动窗口超阈值 单点抖动/坏点丢弃 → **稳态异常事件**
→
③ **根因推理** — ReAct 多步 测点/拓扑/案例/归因 → **根因结论+引用**
→
④ **置信分级** — 三路加权归一 P0致命/P1严重 P2一般/P3提示
→
⑤ **护栏处置** — dry_run→半径→熔断→审批 L0全自动/L1确认/L2建议
→
⑥ **双通道触达** — 钉钉强推 + 卡片 + App 通知
→
⑦ **闭环入库** — 工单→清洗 → 案例 → **RAG**

步	数据形态（输入→输出）	落库	保留策略
①	模拟量/遥测量流 → 时序点	TDengine	热 N 月，冷备归档
②	时序窗口 → 稳态异常事件(JSON)	内存/Redis	瞬时抖动即弃
③	异常事件 → 根因结论 + 证据引用	PostgreSQL	长期（可追溯）
④	结论 → 置信度分数 + 分级	PG(审计)	长期
⑤	分级指令 → 执行/审批/工单草稿	PG + 审计	只追加不覆盖
⑥	告警 → 触达消息	消息中心	按级定投递
⑦	工单 → 案例(RAG 分块+embedding)	向量库	持续迭代沉淀

> **为什么「趋势才可信」：**测点上报告的「告警码」是设备侧判的，可能是误报；只有**连续多个采集周期**都超阈值才升级为稳态异常，单点尖峰/坏点/通信抖动在规则层直接拦截、不进 LLM——这是把告警压缩率做到 85%+ 的第一道闸。

图 3 · 告警研判：ReAct 多步根因推理 + 三路置信度加权

每一步结论都有可追溯的数据依据，置信度由证据量化而来

Step1 取测点
query_metrics(桩,窗口)
拉电压/电流/温度/绝缘

Step2 查拓扑
query_topology(桩)
所属变压器/母线/回路

Step3 检索历史
search_history(相似案)
RAG 召回同类故障

Step4 比对归因
多测点交叉验证
区分「传感器坏/真故障」

三路置信度加权（可逐项解释）

```
置信度 = 规则先验 × 0.40   # 稳态时长/越限幅度/设备
       + RAG 案例相似度 × 0.35  # 历史同型故障
       + 拓扑连锁证据 × 0.25    # 同母线/回路异常联动

输出：单桩根因 + 各证据权重 + 处置建议
```

多测点交叉验证（举例）

现象	判断
仅该桩电压异常，其余测点正常	单桩/传感器故障
同母线多桩电压同步跌落	上级回路/变压器
电压正常 + 温度异常	散热/传感器漂移

研判四原则（降误报的关键细节）

告警码不可信
抖动 / 尖峰 / 断网
产生批量假告警

趋势才可信
连续 N 周期超阈值
才算稳态异常

自适应阈值
阈值=基准+季节偏移
+负载系数，动态调整

多信号交叉验证
电压 + 温度 + 绝缘
同异常才像真故障

告警风暴抑制 + 拓扑连锁归因（关键降噪）

```
故障传播场景：一台变压器 / 母线跳闸 → 几十根桩同步上报异常
   → 若逐桩研判会重复推理、刷屏告警（风暴）

抑制策略：
  ① 拓扑聚合：按「上级变压器 / 母线 / 回路」把告警聚成一个「事件簇」
  ② 锁根节点：ReAct 查拓扑，把同簇告警归到上游根因，子告警折叠为「影响面」
  ③ 只报根因：1 条根因 + N 个受影响桩（影响面），而非 N 条告警
  效果：告警条数从「几十条」收敛到「1 条根因 + 影响面」
```

置信度门控 → 处置动作（低置信不自动）

置信度	紧急度	处置动作
高（≥0.80）	P0/P1	可进护栏链 / 自动或确认执行
中（0.55–0.80）	P1/P2	降级转人工 / 仅出建议
低（< 0.55）	任意	不自动、转人工复核 / 观察

> **置信度为何可解释** 三路里每一路都有数据事实支撑：规则先验来自阈值与稳态时长，RAG 来自检索命中的相似案例，拓扑来自设备台账。模型输出的是「各证据的拟合系数」，不是玄学概率；置信度再向下门控——低于 0.55 的一律不自动执行，交给人工复核。

图 4 • 分级处置（两套正交分级）与安全护栏链

告警紧急度 × 处置自动度解耦；写操作无旁路、可回滚

两套正交分级

告警紧急度	处置自动度
P0 致命（火灾/漏电）	**L0** 全自动执行
P1 严重（主回路）	**L1** 需人工确认
P2 一般（单桩降额）	**L2** 仅出建议转工单
P3 提示（日志异常）	—

两轴组合决定动作：P0×L0 自动；P1/P2 高危×L1 转审批；P3 仅提示。

安全护栏链（高危写操作必经）

```
① dry_run 预演：查目标桩实时状态
   （是否正在充电 / 空闲 / 有无在场车辆）
② 爆炸半径：给桩断电是否波及
   同变压器 / 母线下的其他桩
   → 影响面>1 且高危 → 强制转人工审批
③ 熔断保护：同类动作 60s 内失败≥3 次
   → 自动熔断、转人工排查
④ 人工审批通过 → 执行 → 全量审计
   （写操作只追加、可回滚）
```

> **设计原则：写操作无旁路**——暂停/重启/降功率这些高危写操作一律过护栏链，模型只能出「建议」，不能直接改设备状态；人工审批是第一执行人，审计保证可回溯。

图 5 • 主 Agent 编排状态机（LangGraph 子图隔离 + 条件边路由）

规则优先确定性路由 + LLM 语义介入；子图边界只传结构化 JSON，checkpointer 断点恢复

感知子 Agent
脏数据清洗
滑动窗口稳态判断

→

告警研判子 Agent
降噪 · ReAct 根因
置信度 · P0-P3

→

工单子 Agent
草稿 · 派单
SLA · 闭环

→

RAG 子 Agent
案例检索
方案生成

▲ 条件边：仅当「持续异常事件」才进工单；瞬时抖动 / 坏点在感知层直接拦截 → END（不进 LLM）

确定性路由 vs LLM 介入

环节	谁做
主链路路由 / 条件边	规则（编译期写死）
稳态判断 / 熔断 / 分级	规则

子图隔离 + 结构化中间态

```
子图边界只传 JSON，不传全量对话：
感知 → 异常事件清单
研判 → 根因 + 置信度 + 证据链
```

根因推理 / 歧义仲裁	LLM 语义介入

工单 → 工单草稿
RAG → 检索结论 + 引用

子 Agent 降级 / 重试 / 冲突仲裁（编排稳定性）

子 Agent 超时
单工具调用超时
指数退避重试 2 次

→

失败降级
研判失败 → 降为规则结论
RAG 失败 → 模板兜底

→

歧义仲裁
多子 Agent 结论冲突
主 Agent 按置信度裁决

> **为什么不是「全交给 LLM 自由决策」：** 告警流水线要可审计、可复现、低延迟，主链路用规则优先的确定性状态机路由，LLM 只出现在根因推理、文本泛化这类认知任务；子图隔离让每个子 Agent 职责单一、可替换、可独立降级，checkpointer 支撑断点恢复与全链路审计。

图 6 • 对话助手：两层架构 + 三模式 + 三层记忆 + RBAC + 卡片追问

复用平台能力（工具层 / RAG / 研判落库结论 / 工单 / 护栏链），不重造业务逻辑；同一入口按任务复杂度伸缩自主性

两层架构（业务能力全复用）

应用层
右侧对话浮窗
抽屉 · chips · 卡片 · SSE 流式

▲ /assistant/chat · 统一 API 网关鉴权

能力层
对话助手服务
多轮对话 · 三层记忆 · 按权限调用

▲ 只调用、不重复实现

复用
共享工具层 | **RAG 知识库**
研判落库结论 | **工单服务**
主 Agent 护栏链

三模式伸缩（Workflow ↔ Agent）

模式	流程	自主性
快查「5 号桩状态」	单步取数 / RAG	低 · 确定性
委托「为啥频繁跳闸」	plan→reason ReAct	高 · 自主规划
任务「重启 5 号桩」	precheck→护栏链	低 · 写操作受控

委托类才进 ReAct，简单指令走快车道，复杂才上 Agent，省成本保安全。

三层记忆

层	存储	解决
会话	内存	当轮上下文
短期	Redis 24h	多轮指代 / pending_goal
长期	PG + 向量库	偏好 / 常问设备 / 历史结论

RBAC 四卡点（权限贯穿全链路）

卡点	作用
意图	角色 × 意图 × 范围
数据	按 role 注入场站过滤
调度	能力白名单 dispatch_policy
执行	护栏链 + 全程审计

> **为什么是「入口 + 服务」两层：** 业务能力（研判 / 工单 / RAG）本就在平台能力层，对话服务只调用不重造，保证对话回答与系统研判永远同一份结论。**事件与人双向打通：** P0/P1 告警推卡片到对话浮窗，卡片带「追问」按钮、自动携带告警 ID 进上下文、接上研判结论；对话上下文与主 Agent 流水线状态分家（主 Agent 用 checkpointer 断点恢复，对话用三层记忆），职责不同、物理隔离。

图 7 • 智能运维日报 • 多 Agent 并行生成

每日 7:50 定时唤醒主 Agent；子 Agent 并行产出结构化片段，主 Agent 只做汇总

唤醒
定时任务 7:50
→ 唤醒主 Agent

▼ 主 Agent 并行编排（LangGraph 并行分支）

感知 Agent
在线率 · 充电量
断网统计

告警研判 Agent
故障统计 · 误报过滤
TOP 设备 · 风险总结

工单 Agent
完成率 · 响应时长
无效上门统计

RAG Agent
故障复盘
明日运维建议

▼ 结构化中间态汇聚

汇总
主 Agent 汇总
LLM 生成自然语言结构化日报

▼ 三出口

钉钉群推送 | **后台归档** | **对话窗口日报问答**

> **为什么并行为主**：各片段由子 Agent 并行产出，主 Agent 只做汇总与生成，避免串行慢，也避免把全量原始数据塞进一个超长 Prompt（控 token、防幻觉）。

图 8 · 技术选型与算法接口封装

轻量私有化、场站数据不出内网；算法能力以接口封装对后端暴露

模型清单（按职责分工）

职责	选型
Agent 推理 / 根因 / 多轮对话	Qwen3（4bit 量化）
Embedding 向量化	BGE（中文语义强）
Rerank 重排	bge-reranker

推理用 vLLM 量化；MVP Docker Compose 单机一体化，数据私有化不出内网。

算法接口封装（对后端暴露）

```
/agent/fault        故障研判（ReAct 结论）
/agent/notice       告警内容生成（钉钉侧）
/agent/report       智能日报生成
/agent/rag          RAG 问答
/assistant/chat     对话 SSE 流式
/assistant/action/confirm 确认卡片回调
```

技术选型依据

选型	选型依据
Qwen3（4bit 量化）	中文强、工具调用稳；AWQ/GPTQ 4bit 单卡可跑、降低部署成本
BGE Embedding	中文语义检索效果好，检索召回稳定
bge-reranker	精排提升命中精度，与 BGE 同生态易集成
vLLM 推理	PagedAttention + KV Cache 提升吞吐，服务化稳定

可靠性工程（Agent 稳定运行的底座）

限流熔断
对话并发 Semaphore
高频写操作熔断

→

幂等
工单/推送单号幂等
Redis 判重

→

可观测
Langfuse 全链路 trace
Prometheus 指标告警

→

私有化部署
Docker Compose 单机
场站数据不出内网

> **原则：规则优先、LLM 辅助**——高压故障、告警判定以规则为主，大模型只做总结与推理辅助；高危操作（工单下发、P0/P1 推送）强制人工复核，Agent 只输出推荐结果。

图 9 · 量化评测指标与成果

指标口径可核查：评测集 + 故障标注集 + bad case 回流迭代

指标	口径	目标
告警压缩率	研判后告警条数 / 原始告警条数	≥ 85%
假性 / 抖动故障识别准确率	与人工上门结论比对	≥ 90%
无效上门率	上门后确认为假故障的占比	下降 ≥ 70%
根因定位准确率	与人工诊断结论双人标注比对	≥ 85%
RAG 问答准确率	抽样人工评判	≥ 90%
高危告警推送时延	持续异常判定到钉钉推送	秒级

> **指标可核查的闭环**：告警压缩率是研判前后告警条数的客观比值；根因定位准确率靠双人标注比对；无效上门率来自工单回单「上门结论 = 假故障」的计数，每个数字都有数据出处，非主观估计。